

基于改进粒子群和 BP 神经网络的 网络舆情预测研究^{*}

游丹丹 陈福集

(福州大学经济与管理学院 福州 350108)

摘 要 [目的/意义]网络舆情是一种复杂、多变的系统,通过数据分析并建立网络舆情预测模型来预测其发展趋势具有一定的研究意义。[方法/过程]选择热点话题的百度指数作为网络舆情趋势预测的时间序列指标,采用粒子群算法和 BP 神经网络算法构建了基于改进粒子群算法和 BP 神经网络的网络舆情预测模型,并结合天津港爆炸事件案例进行验证与分析。[结果/结论]实验结果表明该模型在预测的性能上具有一定的优越性,为网络舆情预测提供了一有效模型。

关键词 网络舆情 网络舆情预测 粒子群算法 BP 神经网络

中图分类号 G350 G203

文献标识码 A

文章编号 1002-1965(2016)08-0156-06

引用格式 游丹丹,陈福集.基于改进粒子群和 BP 神经网络的网络舆情预测研究[J].情报杂志,2016,35(8):156-161.

DOI 10.3969/j.issn.1002-1965.2016.08.027

Research on the Prediction of Network Public Opinion Based on Improved PSO and BP Neural Network

You Dandan Chen Fuji

(School of Economics and Management, Fuzhou University, Fuzhou 350108)

Abstract [Purpose/Significance] Network public opinion is a complex and changeable system, it is significant to predict its tendency accurately based on data analysis and establishing prediction model of network public opinion. [Method/Process] The paper selects the Baidu index of hot topics as the index of time series for predicting the trend of network public opinion, employing Particle Swarm Optimization and BP neural network to construct the prediction model based on improved particle swarm algorithm and BP neural network, and then verifies and analyzes the experimental results combined with the case of Tianjin explosion. [Result/Conclusion] The results show that the model has certain superiority in prediction and provides an effective model for the prediction of network public opinion.

Key words network public opinion prediction of network public opinion particle swarm algorithm BP neural network

0 引 言

随着互联网技术的不断发展,人们通过互联网表达政治诉求、参与政治生活以及对公共权力的监督越来越直接、快捷与公开化,互联网成为网民不可或缺的一个表达民意、民情的平台。根据中国互联网络信息中心(CNNIC)公布的第37次《中国互联网络发展状况报告》显示,截至2015年12月,中国网民的数量达

到6.88亿,互联网普及率达到50.3%,中国居民上网人数已过半^[1]。网民队伍的不断扩张,逐渐成为网络舆情传播的中坚力量,网民在网上的声音也让政府能够快速直接地了解民情、民意以及社会的发展状况。然而,网络的自由、多元化也是一把双刃剑,从近几年网络舆情引起的危机事件爆增的现象就可以看出,因此,面向网络舆情的预测需求刻不容缓^[2]。

收稿日期:2016-04-21

修回日期:2016-05-16

基金项目:国家自然科学基金项目“基于知识网格面向网络舆情的政府决策知识供需匹配研究”(编号:71271056)。

作者简介:游丹丹(ORCID:0000-0003-2792-8688),女,1991年生,硕士研究生,研究方向:网络舆情、数据挖掘;陈福集(ORCID:0000-0003-3569-8448),男,1953年生,教授,博士生导师,研究方向:网络舆情、数据挖掘。

1 网络舆情预测研究概况

1.1 相关预测方法 预测方法在各个领域得到了广泛的应用,并起到了举足轻重的作用。常见的预测

模型有两大类:以数理统计和微积分等传统的数学物理方法为基础的预测模型、基于智能机器学习算法的预测模型^[3]。部分常见的具有代表性的预测模型如表 1 所示。

表 1 常见的预测模型

类型	模型	原理及优缺点
基于传统统计学的预测方法 ^[4]	微分方程模型	该方法基于假设条件来建立不同方程,其适用于短、中、长期的预测,它能够分析事物的内部实质关系,精度相应的也比较高,但由于模型的建立主要是基于局部独立的假设条件为基础,因此在中长期预测时,存在较大误差
	时间序列模型	常见的模型有差分自回归移动平均 (ARIMA)、指数平滑法、加权移动平均法等,该方法突出时间因素在预测中的作用,考虑因素比较单一,不考虑外界其他影响因素,当其他外界因素影响波动大时,存在较大的预测误差的缺陷,较适用于中短期的预测
	参数回归模型	该方法在分析多因素的模型时,简单方便,能够准确计量各个因素之间的相关程度和回归拟合程度的高低,具有较好的预测效果,但在回归分析中,因子的选择和表达方式难以确定,以及回归方程式只是一种预测,直接影响到因子的多样性、不可测性,导致回归分析在某些情况下受到限制
	灰色理论模型	该方法首先将已知的数据序列按照某种规则构成动态、非动态的白色模块,再通过使用某种变化方法求求解。其具有不需要大量数据、能解决历史数据匮乏、序列不够完整和数据可靠性低问题的特点,是处理小样本预测问题的有效途径,且运算简单、易于检验和不必考虑分布规律的特点。但其对波动性大的序列预测结果较差
基于智能机器学习算法的预测方法 ^[5]	支持向量机模型	该算法能够通过寻求结构化风险最小来提高学习泛化能力;在小样本的情况下,也能获得良好统计规律;可以解决非线性问题和高维问题。但其对缺失数据敏感,对非线性问题没有通用的解决方式,必须谨慎选择核函数来处理
	神经网络模型	该方法基于学习训练法则,通过训练来调整网络连接权值和阈值,以达到目标的收敛。它具有理论依据坚实、推导过程严谨、预测精度高、对噪声有较强的鲁棒性以及能够充分逼近复杂的非线性关系,但也存在预测人员无法参与预测过程、收敛速度慢、网络容错能力较低,需要大量参数,算法不完备易于陷入局部极小的缺点
	马尔科夫模型	马尔科夫理论具有平稳性,但是其核心部分是通过划分状态空间来构造状态转移矩阵,这种概念估计模型的预测精确性依托于未来一期的预测,且所选择的拟合曲线也对预测的精确性影响较大

以上模型中,应用比较多的是时间序列模型,该类模型简单、易实现,但是他们更适用于线性关系的预测。现代预测方法是基于非线性理论模型的,其预测精度相对传统预测方法要高。

1.2 网络舆情预测研究现状 网络舆情预测指通过获取、分析、预测等技术来对网络舆情未来发展方向进行预测,它一般包括网络舆情数据采集、数据预处理、网络舆情预测模型建立以及预测发展趋势^[6]。

随着网民规模的不断扩大,网络舆情事件近几年呈现爆发式的增长,研究网络舆情的学者也越来越关注网络舆情预测,并取得客观的成果。根据题名或关键词(网络舆情、预测)在知网模糊检索 2005 年至 2016 年关于舆情预测的相关文献获得 49 篇。通过整理发现,关于网络舆情预测的研究起步比较晚,2005 ~ 2007 年几乎没有相关研究,2008 年之后才逐步上升,并且随着网络规模的不断扩大,近 3 年关于网络舆情预测的研究较多,从 2015 年的文献数量来看,关于网络舆情预测研究的增长幅度有所降低,但相对网络舆情这个大方向的研究来说,网络舆情预测研究尚处于起步阶段,且网络舆情预测研究对解决和应对舆情危机具有较好的导向性。2007 年至 2016 年文献数量变化趋势如图 1 所示。




图 1 2007 - 2016 年文献数量变化趋势

我国的网络舆情研究起步相对比较晚,而且大多研究以定性研究为主,在可操作性的性能上比较薄弱,目前应用于网络舆情预测的模型比较缺乏,对网络舆情的预测研究还处于探索阶段。

网络舆情预测研究主要从热点话题的发现、舆情事件演化趋势、网络舆情时间序列数据收集、预测模型的建立与预测等方面展开。目前研究网络舆情预测的方法渐多,主要是将人工智能和时间序列预测技术两者结合起来进行网络舆情预测研究。张一文等构建了基于贝叶斯网络建模的网络舆情态势评估与预测模型,但贝叶斯网络本身无法确保收敛,且先验知识的获取具有一定的主观性^[7];黄敏、胡学钢针对网络舆情变化的时变性和混沌性的特点,将混沌理论融入到网络舆情建模的预测之中,在相空间中建立了基于支持向

量机的网络舆情混沌预测模型 (PHR-SVR), 该模型提高了网络舆情预测精度, 有助于更准确判断网络舆情的发展趋势^[8]; 刘勘、李晶、刘萍采用了马尔科夫链对网络舆情的热度趋势进行分析估计, 但其核心部分是通过划分状态空间来构造状态转移矩阵, 这种概念估计模型的预测精确性依托于未来一期的预测, 且所选择的拟合曲线也对预测的精确性影响较大^[9]; 张珏采用热点话题的帖子、网络新闻、博客文章的回复数作为原始时间序列, 建立了基于指数平滑模型、ARIMA 模型和 BP 神经网络的热点话题发展趋势预测, 其中, 指数平滑模型适合应用于时间序列平稳的情况, 对中长期预测偏差较大, ARIMA 模型主要针对线性的非平稳时间序列进行预测, BP 神经网络能够逼近复杂的非线性关系, 但其易于陷入局部极小^[10]; 王沙沙通过 Google Trends 获取某事件的时间序列, 对其进行曲线拟合聚类, 形成长期趋势预测的类库, 继而根据新事件的所属类别选择预测模型, 并对其进行长期发展趋势进行预测分析, 但其预测效果取决于周期分析和层次聚类的结果, 以及所形成的类模型库的全面性和客观性^[11]。李振提出的基于灰色模型和加权马尔科夫的网络舆情预测模型, 取得了较好的预测效果^[3]; 蒋玉婷提出了基于数据挖掘技术的网络舆情组合预测模型, 该模型首先使用灰色模型进行预测, 为了提高预测精度, 然后采用粒子群算法改进的 BP 神经网络对灰色模型预测的结果进行修正, 结果表明, GM-PSO-BPNN 模型能够深入挖掘网络舆情内在的变化规律, 提高了预测的精度^[12], 与本文不同的是, 其主要采用 GM 模型进行预测, 将 GM 模型的预测值与实际值的残差作为 BPNN 的输入, 然后将 BPNN 输出的残差预测值与 GM 模型的预测值进行融合得到最终结果, 另外, 其粒子群算法没有做相关的改进。而本文将预处理后的时间序列数据作为 BP 神经网络的输入, 其中, BP 神经网络的初始参数通过改进后的粒子群算法进行优化后得到, 最后将预测结果进行反归一化得到实际预测值。

其中 BP 神经网络模型具有逼近效果好, 计算效率高, 无需建立数学模型, 具有很强的非线性拟合能力^[13]。但是 BP 神经网络也存在容错能力差, 算法容易陷入局部最小值, 收敛速度慢、学习具有不稳定性等缺点, 因此, 为了提高 BP 神经网络预测模型的预测准确性, 本文提出基于改进粒子群算法优化 BP 神经网络的网络舆情预测方法。

2 预测模型的相关理论

2.1 BP 神经网络 神经网络技术在较多领域中得到了广泛的应用, 其中 BP 神经网络的应用范围最

广^[14]。BP 神经网络全称为 Back-Propagation Network, 即反向传播网络, 由 Rumelhart, McClelland 于 1985 年提出, 它是一种单向传播的多层前向网络, 其利用误差反向传播方法进行训练。它具有结构简单、可塑性强以及对噪声数据的承受能力高等特点, 因此在信息分类、模式识别以及预测等领域得到了广泛的应用^[15]。

BP 神经网络是一种具有三层或三层以上的神经网络, 包含输入层、隐含层(可包含多层)和输出层, 上下层之间实现全互连, 而同一层的神经元之间无连接^[2]。其利用输出后的值与真实值比较得来的误差来估计其直接前导向层的误差, 再利用这个误差估计更前一层的误差, 如此一层一层的反向传播下去, 获得所有其他各层的误差估计, 随着误差的逆向传播和修正不断地进行, 网络对输入模式响应的正确率不断上升。

2.2 粒子群算法 粒子群优化算法 (Particle Swarm Optimization, PSO 算法) 是一种进化计算技术, 由 Kennedy 和 Eberhart 在 1995 年提出, 源于对鸟群捕食的行为研究^[16]。该算法是一种基于迭代的优化工具, 它模拟鸟群飞行觅食的行为, 鸟之间通过集体的协作使群体达到最优目的。

在粒子群算法中, 每个待优化问题的解抽象为一个微粒, 并将其延伸到 N 维空间。所有的粒子都有一个速度来决定搜索的方向和距离, 以及一个待优化目标函数决定的适应度值 (fitness)。每个粒子知道所经历过的最优位置 pbest 和当前位置, 即粒子有自己的飞行经验, 另外, 还知道截至目前整个群体中发现的最优位置 (gbest), 即粒子知道其他同伴的经验, 粒子根据自己的飞行经验和其他同伴的最优经验来决定下一步的运动位置^[16]。

3 预测模型的构建

3.1 标准 BP 神经网络预测模型 BP 神经网络采用 3 层拓扑结构, 对于网络舆情预测而言, 本文采用 5 天为周期的时间序列进行第 6 天的预测, 因此输入层节点数设置为 5, 输出层节点数设置为 1。设置最大迭代次数 3000, 训练的目标误差为 $1e-5$, 学习速率为 0.05, 动量因子为 0.9。由于 \log_{sig} 函数能够将神经元的输入值映射到 $[0, 1]$ 范围内, 因此隐含层传递函数设置为 “ \log_{sig} ”, 输出层传递函数设置为 “ \log_{sig} ”。另外训练算法设置为 traingdx 函数。

关于隐含层节点数, 首先根据经验公式 (1) 计算得到估计值, 再以此估计值附近数值进行试错, 将隐含层节点数从 4~16 依次试错, 发现隐含层节点数设为 6 时, 均方误差较小, 预测结果拟合程度较好, 因此将 BP 神经网络的隐含层节点数设置为 6。

$$\text{hiddennum} = \sqrt{\text{indim} + \text{outdim}} + a \quad a = \{1, 2, \dots, 10 \mid \text{整数}\} \quad (1)$$

其中 indim 为输入层单元数, hiddennum 为隐含层单元数, outdim 为输出层单元数, a 为 1 到 10 之间的整数。

表 2 隐含层不同节点数的训练后的 mse

隐含层节点数	迭代次数	mse	隐含层节点数	迭代次数	mse
4	3000	0.0004235	10	3000	0.0002444
5	3000	0.0003388	11	3000	0.0003817
6	3000	0.0002384	12	3000	0.0003323
7	3000	0.0002999	13	3000	0.0002901
8	3000	0.0003480	14	3000	0.0003241
9	3000	0.0002844	15	3000	0.0002975

3.2 权重改进的 PSO 优化 BP 神经网络 粒子群算法采用常数学习因子 c_1 和 c_2 以及惯性权重 w , 其中, 较大的惯性权重 w 有利于跳出局部极小点从而提高算法的全局搜索能力, 而较小的惯性权重则有利于对当前的搜索区域进行精确局部搜索从而增强算法的局部搜索能力和加快算法的收敛。因此, 为了使算法在搜寻的早期具有较强的全局寻优能力, 以及在搜索后期可以进行精确局部搜索, 采用线性变化的权重来改善 PSO 算法后期易在全局最优解附近产生震荡和容易早熟的现象^[16]。

改进后的粒子群算法优化 BP 神经网络的关键步骤如下:

步骤 1 随机初始化种群中各粒子的初始位置和速度, 设置粒子的速度范围、位置范围、初始惯性权重 w 、学习因子 c_1 和 c_2 、种群规模、迭代次数以及 BP 神经网络的拓扑结构等。对于一个具有 indim 个输入层, hiddennum 个隐含层, outdim 个输出层的 3 层 BP 神经网络来说, 粒子群中自变量的个数为:

$$d = (\text{indim} + 1) * \text{hiddennum} + (\text{hiddennum} + 1) * \text{outdim} \quad (2)$$

步骤 2 根据适应度函数计算每个粒子的适应度值, 确定粒子的个体历史最优值和所有粒子的全局最优值。对于每个粒子, 将其适应度值与其历史极值作比较, 将目前为止各粒子本身的最优位置存储在 P_b 中^[17]; 对于每个粒子, 将其最优适应度值与全局最优适应度值比较, 将最优 P_b 存储在 P_g 中。适应度函数如公式 3:

$$F = \frac{1}{2} \sum_{t=1}^s \sum_{k=1}^{\text{outdim}} (T_k - O_k)^2 \quad t = 1, 2, \dots, s; k = 1, 2, \dots, \text{outdim} \quad (3)$$

其中, s 为迭代次数, outdim 为输出单元个数, $(T_k - O_k)$ 为期望输出和网络预测输出的误差。

步骤 3 按以下公式更新每个粒子的速度 $v_{ij}(t +$

1) 和位移 $x_{ij}(t + 1)$, 并使其在限定的范围之内, 其中 t 为当前的迭代步数。

$$v_{ij}(t + 1) = wv_{ij}(t) + c_1r_1[p_{ij} - x_{ij}(t)] + c_2r_2[p_{gj} - x_{ij}(t)] \quad (4)$$

$$x_{ij}(t + 1) = x_{ij}(t) + v_{ij}(t + 1) \quad i = 1, 2, \dots, n; j = 1, 2, \dots, d \quad (5)$$

公式中, r_1 和 r_2 表示 0 ~ 1 之间的随机数, C_1 、 C_2 表示学习因子, n 表示粒子的数量, d 表示解的 d 维空间, 即自变量个数。

步骤 4 更新粒子群算法的惯性权重 w , 其随着算法迭代次数的线性变化结果为:

$$w = w_{\max} - \frac{t^* (w_{\max} - w_{\min})}{t_{\max}} \quad (6)$$

其中, w_{\max} 、 w_{\min} 分别表示粒子群算法的惯性权重的最大值、最小值, t_{\max} 表示最大迭代次数, t 表示当前的迭代步数。

步骤 5 重复步骤 2 至步骤 4, 直至达到预设的运算精度和迭代步数, 搜索停止, 输出结果, 此时得到优化后的连接权值和阈值, 将其作为 BP 神经网络训练的初始连接权值和阈值。

步骤 6 进行 BP 神经网络训练, 直至达到预设的最大训练次数或者满足最小误差需求。

步骤 7 将通过改进粒子群算法优化后的 BP 神经网络用于网络舆情预测。

改进粒子群算法优化 BP 神经网络的本质是将 BP 神经网络的训练误差作为粒子群算法的待优化目标函数, 从而评价各粒子的适应度值, 通过不断迭代、更新并寻找最优粒子所在的位置, 最后得到 BP 神经网络的较优初始连接权值和阈值。

相关参数设置: 种群大小 n 设置为 40, 两个学习因子 c_1 、 c_2 分别为 2 和 1.8, 粒子的范围即自变量的个数根据公式 2 设置为 43, 粒子的初始化位置在 $[-1, 1]$ 之间, 粒子的初始化速率在 $[-1, 1]$ 之间, 惯性权重范围在 $[0.90, 0.30]$ 之间, 最大迭代次数为 100。

改进后的粒子群算法优化 BP 神经网络的算法流程图如图 2 所示。

4 实例分析

4.1 样本数据与处理 本文首先获取 2015 年 8 月份“天津港爆炸”“七夕情人节”“旋风少女”等部分热门话题, 如表 3 所示。话题主要涉及突发事件、民生热点、综艺娱乐以及节日等多个方面。

取天津港爆炸事件的网络舆情数据(取自百度指数) 2015 年 8 月 13 号至 2015 年 9 月 11 号的时间序列数据为用于模型的训练和预测。该事件时间序列趋势如图 3 所示。本文预测采用滚动式方法, 即 5 天为一

个周期,用前 5 天的的时间序列进行第 6 天的预测。数据分为 30 组,取 15 组的时间序列数据用于模型训练,15 组的时间序列数据用于预测。

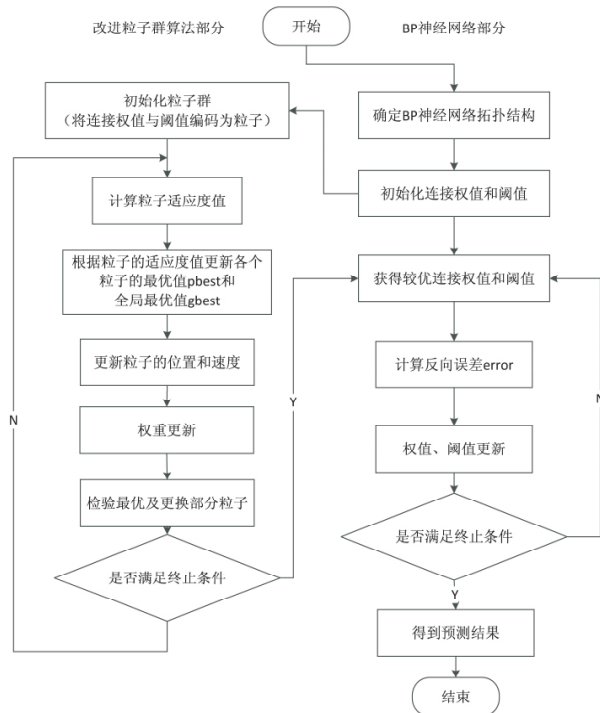


图2 算法流程

表3 2015年8月份部分热点话题

序列	话题	提及度	热搜度
1	天津港爆炸	17949400	178523
2	七夕	15356552	15960
3	旋风少女	5423817	360323
4	真心英雄	4982231	89450
5	花千骨	5127634	79322
6	偶像来了	4007123	213850
7	回忆专用小马甲	2764334	39076
8	杨洋微微一笑很倾城	2190876	987
9	克拉恋人	2017342	400123
10	对嘴大赛	1732972	4821




图3 天津港爆炸话题网络舆情时间序列趋势

4.2 仿真及结果分析 本文的仿真工具为 matlab2010,为了验证基于改进粒子群优化 BP 神经网络

的有效性以及更好比较预测结果,分别建立了基于标准 BP 神经网络的网络舆情预测模型、基于改进粒子群优化 BP 神经网络的网络舆情预测模型。实验结果对照如表 4 所示,模型预测结果对比图如图 4 所示。




图4 模型预测结果对比

表4 实验结果对照

时间	原始值 (期望输出)	标准 BP 神经网络模型 的输出	改进 PSO 优化 BP 神经网络模型 的输出	标准 BP 神经网络模型预测 相对误差	改进 PSO 优化 BP 神经网络模型预测 相对误差
8 月 28 号	43312	43243	43806	-0.0016	0.0114
8 月 29 号	37399	43081	39189	0.1519	0.0479
8 月 30 号	28201	41384	34664	0.4675	0.2292
8 月 31 号	28267	33779	29628	0.1950	0.0481
9 月 1 号	24875	28430	28277	0.1429	0.1368
9 月 2 号	22783	25027	25421	0.0985	0.1158
9 月 3 号	22695	22836	23361	0.0062	0.0293
9 月 4 号	23959	21362	21823	-0.1084	-0.0892
9 月 5 号	21543	19262	21738	-0.1059	0.0091
9 月 6 号	20740	17510	20315	-0.1557	-0.0205
9 月 7 号	21527	17651	19562	-0.1801	-0.0913
9 月 8 号	20380	16987	19452	-0.1665	-0.0455
9 月 9 号	16181	15906	18762	-0.0170	0.1595
9 月 10 号	14327	15077	16338	0.0523	0.1404
9 月 11 号	13707	14691	14484	0.0718	0.0567
平均 相对误差	-	-	-	0.1281	0.0820

由表 4 的预测结果可以看出,从拟合性能和预测精度指标上看,相比于标准 BP 神经网络模型,改进粒子群优化 BP 神经网络模型的预测结果表现得更加优越。由图 4 可以看出,改进粒子群优化 BP 神经网络模型的预测结果与真实值拟合得较好,预测结果更接近真实值。而基于标准 BP 神经网络模型的预测结果稳定性较差,浮动较大,预测精度上也有所欠缺。改进粒子群优化 BP 神经网络模型的预测值的平均相对误差明显小于基于标准 BP 神经网络模型,前者为 0.0820,后者为 0.1281。图 5 为两个模型预测的误差曲线图,从中也可看出基于改进粒子群优化 BP 模型的预测结果相对误差整体较为稳定。图 6 为改进粒子群以 BP 神经网络的训练误差最小化为目标的训练过程的适应值变化曲线图。

从运行的时间效率上来看,标准 BP 神经网络模

型的运行时间在10秒左右,而改进粒子群优化BP神经网络模型的运行时间在1.5分钟左右,虽然改进后的BP神经网络模型在运行时间效率上处于一定劣势,但是对于注重追求准确率的网络舆情预测来说,其劣势在一定程度上可接受。




图5 相对误差




图6 适应度值变化

5 总结

网络舆情是一种复杂、多变的系统,具有爆发性、演变不确定性、隐匿性、互动性等特点,对其进行准确的预测,有利于相关部门能够及时发现潜在隐匿的舆情危机,准确判断舆情事件的发展态势,并对其进行正确、有效的引导^[19]。

本文通过选择热点话题的百度指数作为网络舆情趋势预测的时间序列指标,构建了基于标准BP神经网络和基于改进粒子群算法优化BP神经网络的网络舆情预测模型。运用改进粒子群算法优化BP神经网络的初始连接权值和阈值,在一定程度上改善了BP神经网络易于陷入局部最优的问题,继而建立网络舆情预测模型并使用matlab工具进行编程,采用选取的训练数据来训练已建立的预测模型,从而确定BP神经网络的结构和参数,最后将测试样本代入训练好的预测模型进行预测,并对预测结果进行分析,对比模型的预测结果的拟合程度、相对误差,结果表明,本文建立的基于改进粒子群优化BP神经网络的网络舆情预测模型是有效的,预测的精准率明显高于基于标准BP神经网络预测模型。

本文的创新在于:以往收集时间序列一般以事件的转发数或回复数构成,本文以百度指数作为获取时间序列的指标更为全面;将改进的粒子群算法和BP

神经网络智能算法混合应用于网络舆情的预测之中,为网络舆情预测提供了另一有效模型,但由于网络舆情传播本身比较复杂,本文研究善处于探索阶段,有待于更深入的研究,做到网络舆情事前准确预测。

参考文献

- [1] 中国互联网络信息中心(CNNIC). 第37次中国互联网络发展状况统计报告[R]. 2016.
- [2] 薛圈圈. 基于BP神经网络的网络舆情危机预警研究[J]. 图书情报工作, 2011(20): 59-63.
- [3] Candes E J, Wakin M B. An introduction to compressive sampling[J]. IEEE Signal Processing Magazine, 2008, 25(2): 21-30.
- [4] Huang H C, Chang F C, Wu C H, et al. Watermarking for compressive sampling applications[C]//Proceedings of the 2012 8th International Conference on Intelligent Information Hiding and Multimedia Signal Processing, Washington: IEEE, 2012: 223-226.
- [5] Zeng J P, Zhang S Y, Wu C R, et al. Predictive model for Internet public opinion[C]//Fourth International Conference on Fuzzy Systems and Knowledge Discovery. Haikou: IEEE Press, 2007: 7-11.
- [6] 李振. 网络舆情预测关键技术研究[D]. 郑州: 郑州大学电气工程学院, 2010.
- [7] 张一文, 齐佳音, 方滨兴, 等. 基于贝叶斯网络建模的非常规危机事件网络舆情预警研究[J]. 图书情报工作, 2012, 56(2): 76-81.
- [8] 黄敏, 胡学钢. 基于支持向量机的网络舆情混沌预测[J]. 计算机工程与应用, 2013, 49(24): 130-134.
- [9] 刘勘, 李晶, 刘萍. 基于马尔可夫链与舆情热度趋势分析[J]. 计算机工程与应用, 2011, 47(36): 170-173.
- [10] 张珏. 网络舆情预测模型与平台的研究[D]. 北京: 北京交通大学, 2009.
- [11] 王沙沙. 基于类模型的Web舆情趋势预测[D]. 成都: 电子科技大学, 2011.
- [12] 蒋玉婷. 数据挖掘技术在网络舆情预测中的应用[J]. 科技通报, 2013, 29(10): 73-75.
- [13] 张华. 基于优化BP神经网络的微博舆情预测模型研究[D]. 武汉: 华中师范大学计算机学院, 2014.
- [14] 葛哲学, 孙志强. 神经网络理论与MATLAB R2007实现[M]. 北京: 电子工业出版社, 2007: 46-60.
- [15] Jiawei Han, Micheline Kamber. 数据挖掘概念与技术[M]. 范明, 孟小峰译. 北京: 机械工业出版社, 2007: 212-217.
- [16] 龚纯, 王正林. 精通MATLAB最优化计算[M]. 2版. 北京: 电子工业出版社, 2012: 270-312.
- [17] 田雨波. 混合神经网络技术[M]. 北京: 科学出版社, 2009: 104-118.
- [18] 黄艳, 臧传治, 于海斌. 基于改进粒子群优化的无线传感器网络定位算法[J]. 控制与决策, 2012, 27(1): 156-160.
- [19] 曾振东. 基于灰色支持向量机的网络舆情预测模型[J]. 计算机应用与软件, 2014, 31(2): 300-302.

(责编: 王平军; 白燕琼)