

改进粒子群—BP 神经网络模型的短期电力负荷预测

师彪¹, 李郁侠¹, 于新花², 闫旺¹

(1. 西安理工大学 水利水电学院, 西安 710048; 2. 青岛科技大学 职业技术学院, 山东 青岛 261000)

(biaosh2008@163.com)

摘要:为了准确、快速、高效地预测电网短期负荷,提出了改进的粒子群算法(MPSO),并与BP算法相结合,形成改进的粒子群—BP(MPSO-BP)神经网络算法,用此算法训练神经网络,实现了神经网络参数优化,得到了基于MPSO-BP算法的神经网络模型。综合考虑气象、天气、日期类型等影响负荷的因素,进行电网短期负荷预测。算例分析表明,与传统BP神经网络法和PSO-BP神经网络方法相比,该方法改善了BP神经网络的泛化能力,预测精度高,收敛速度快,对电力系统短期负荷具有良好的预测能力。

关键词:短期负荷预测;改进的粒子群—BP神经网络算法;预测精度

中图分类号: TM614; TP18 **文献标志码:** A

Short-term load forecast based on modified particle swarm optimizer and back propagation neural network model

SHI Biao¹, LI Yu-xia¹, YU Xin-hua², YAN Wang¹

(1. Institute of Water Resources and Hydro-electric Engineering, Xi'an University of Technology, Xi'an Shaanxi 710048, China;

2. Technical Institute of High Vocation, Qingdao University of Science and Technology, Qingdao Shandong 261000, China)

Abstract: Aiming at improving the power short-term forecast accuracy and speed, the Modified Particle Swarm Optimizer (MPSO) algorithm was presented. The forecast model was set up by combining with the Back Propagation (BP) neural network to form Modified Particle Swarm Optimizer and Back Propagation (MPSO-BP) neural network algorithm, and then the neural network was trained by using the MPSO-BP algorithm. It can automatically determine the parameters of the neural network from the sample data. The power short-term forecast model based on the MPSO-BP neural network was formed with considering weather, date and other factors. The experimental results show that the MPSO-BP algorithm improves the BP neural network generalization capacity, and the convergence of method is faster and forecast accuracy is more accurate than that of the traditional BP neural network. Therefore, the model can be used to forecast the short-term load of the power system.

Key words: short-term load forecast; Modified Particle Swarm Optimizer and Back Propagation (MPSO-BP) neural network algorithm; forecast accuracy

0 引言

电力负荷的准确预测对于电力生产和电网安全运行以及国民经济都有着重要意义^[1]。多年来负荷预测一直是国内外研究的热点,前人在此领域已取得一定成果^[2-3]。传统的预测方法如时间序列法、回归分析法和模式识别法等都存在各自的缺陷。

传统的BP神经网络具有较好的非线性和自学习能力,但常出现易振荡、收敛速度慢,易陷入局部极小值和隐含层神经元个数难以确定等缺点^[4],并且对于具有随机性的电力负荷而言,缺乏精确数据筛选处理能力。

粒子群优化算法(Particle Swarm Optimizer, PSO)具有依赖的经验参数较少、收敛速度快等优点,但也存在易陷于局部极值、收敛精度不高的缺陷。本文对PSO算法加以改进,并将改进粒子群优化算法(Modified Particle Swarm Optimizer, MPSO)用来训练神经网络的参数,从而优化网络,实现BP(Back Propagation)神经网络参数自动优化,建立了基于改进的粒子群—BP(Modified Particle Swarm Optimizer and Back

Propagation, MPSO-BP)神经网络算法的短期负荷预测模型,编制了基于Matlab^[5]和VC++语言的优化计算程序,并把该模型用于某地短期负荷预测系统中。结果表明,该方法加快了网络学习速度,提高了负荷预测精度,并能加强BP的泛化能力。

1 PSO算法及其改进

1.1 基本粒子群优化算法

粒子群优化算法^[6]是基于群智能的全局优化技术,它通过粒子间的相互作用,对解空间进行智能搜索,从而发现最优解。

设在一个 D 维的目标搜索空间中,有 N 个粒子组成一个群落,其中第 i 个粒子代表一个 D 维向量 $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{id})$,即第 i 个粒子在 D 维搜索空间中的位置。而每个粒子的位置 \mathbf{x} ,为一个潜在的解。将 \mathbf{x} 代入一个目标函数即可算出其适应值,根据适应值的大小衡量 \mathbf{x} 是否为所要求解的最优解。第 i 个粒子的“飞翔”速度也是一个 D 维向量,记为 $\mathbf{v}_i = (v_{i1}, v_{i2}, \dots, v_{id})$ 。记第 i 个粒子到第 h 次迭代为止搜索到的最优位

收稿日期:2008-10-28;修回日期:2008-12-12。 基金项目:国家火炬计划创新基金资助项目(07C26213711606);陕西省自然科学基金基础研究计划项目(SJ08E220);山东省软科学基金资助项目(2007RKB188)。

作者简介:师彪(1975-),男,甘肃定西人,高级工程师,博士,主要研究方向:电网规划及电力市场;李郁侠(1952-),男,陕西杨凌人,教授,博士生导师,博士,主要研究方向:电网规划及电力市场;于新花(1976-),女,山东青岛人,副教授,硕士,主要研究方向:电力自动化;闫旺(1981-),男,河北涞水人,硕士研究生,主要研究方向:电网规划及电力市场。

置为 $P_i = (P_{i1}, P_{i2}, \dots, P_{id})$, 整个粒子群到第 h 次迭代为止搜索到的最优位置为 $P_{igd} = (P_{i1}, P_{i2}, \dots, P_{id})$ 。算法的基本公式如下:

$$v_{id}^{(k+1)} = \omega v_{id}^{(k)} + c_1 r_1^{(k)} (P_{id}^{(k)} - x_{id}^{(k)}) + c_2 r_2^{(k)} (P_{gd}^{(k)} - x_{id}^{(k)}) \quad (1)$$

$$x_{id}^{(k+1)} = x_{id}^{(k)} + v_{id}^{(k+1)} \quad (2)$$

其中: c_1, c_2 为加速系数, 分别调节向全局最好粒子和个体最好粒子方向飞行的最大步长, 合适的 c_1, c_2 既可加快收敛又不易陷入局部最优; r_1, r_2 为 $[0, 1]$ 之间的随机数。

算法迭代终止条件一般选为最大迭代次数或粒子群迄今为止搜索到的最优位置的适应度值满足预定的最小适应度阈值。

PSO 算法操作简单, 使用方便, 收敛速度快。但算法也存在以下问题:

1) 粒子都是根据全体粒子和自身的搜索经验向着最优解的方向“飞行”, 在较大的惯性因子的作用下, 粒子有可能会缺乏对最优解的精细搜索而导致搜索精度不高;

2) 所有粒子都向最优解的方向“飞行”, 越接近最优粒子, 其速度越小, 所以粒子群趋向同一, 失去粒子间解的多样性, 因而易于收敛到局部最优。

1.2 改进的粒子群算法

MPSO 算法的改进思想为: 根据每个粒子在同一速度方向上, 以大小不同的幅值飞行, 把新生粒子分类, 大的速度幅值的粒子进行全局寻优, 另一类进行局部寻优。具体方法: 从这些位置中选择个体和全局最优位置“极值”来更新粒子速度。大的速度幅值满足粒子全局搜索要求, 避免陷入局部最优和早熟现象; 小的速度幅值满足细化搜索要求, 避免飞越最优解空间, 较快求得最优解。公式如下:

$$\begin{cases} v_{id}^{(k+1)} = \omega v_{id}^{(k)} + c_1 r_1^{(k)} (P_{id}^{(k)} - x_{id}^{(k)}) + c_2 r_2^{(k)} (P_{gd}^{(k)} - x_{id}^{(k)}) \\ x_{id}^{(k+1)} = x_{id}^{(k)} + v_{id}^{(k+1)} \\ v_{id}^{(1)} = a(1)v_{id}^{(0)}, \dots, v_{id}^{(m)} = a(m)v_{id}^{(0)}, \dots, v_{id}^{(j)} = a(j)v_{id}^{(0)}; m = 1, 2, \dots, j \\ x_{id}^{(1)} = x_{id}^{(0)} + v_{id}^{(1)}, \dots, x_{id}^{(m)} = x_{id}^{(0)} + v_{id}^{(m)}, \dots, x_{id}^{(j)} = x_{id}^{(0)} + v_{id}^{(j)}; m = 1, 2, 3, \dots, j \end{cases} \quad (3)$$

其中: r_1, r_2 为介于 $[0, 1]$ 之间的随机数; c_1, c_2 为加速度系数; ω 为惯量因子; $v_{id}^{(0)}$ 称为粒子 i 第 d 维的基准速度分量; $v_{id}^{(m)}$, $m = 1, 2, \dots, j$ 称为粒子 i 第 d 维的搜索速度分量; j 称为速度间隔数; $x_{id}^{(0)}$ 称为粒子 i 第 d 维的基准位置分量; $x_{id}^{(m)}$, $m = 1, 2, \dots, j$ 称为粒子 i 第 d 维的搜索位置分量; P_{id} 为粒子 i 以不同速度所经历的第 d 维最好位置分量; P_{gd} 为目前粒子群以不同速度在解空间中所经历的最好位置。

$a(m)$, $m = 1, 2, \dots, j$ 称为速度变系数, 用来决定搜索速度与基准速度的关系。确定两者关系的原则是: 设一个最大速度 M_{i1} 和最小速度 M_{i2} , 若 $v_{id}^{(0)} > M_{i1}$, 则 $a(m)$ 把搜索速度变小; 若 $v_{id}^{(0)} < M_{i2}$, $a(m)$ 把搜索速度变大; 若 $M_{i1} < v_{id}^{(0)} < M_{i2}$ 速度合适时, $a(m)$ 把搜索速度在 $v_{id}^{(0)}$ 两边变大和变小, 只有这样, 粒子才能搜索到足够的解空间。因此, 公式为:

$$a(m) = \begin{cases} m, & v_{id}^{(0)} < m_{i2} \\ m/j, & v_{id}^{(0)} \geq m_{i1} \\ 1 \pm m/j, & m_{i2} < v_{id}^{(0)} < m_{i1} \end{cases} \quad (4)$$

研究表明^[7], 惯性因子 ω 对算法的优化性能有很大的影响, 较大的 ω 值有利于提高算法的收敛速度, 而 ω 较小时则有利于提高算法的收敛精度。据此提出一种按式(5)对 ω 进行自适应调整的策略, 即随着迭代的进行, 逐步减少 ω 值。

$$\omega(k) = \left[\frac{2}{(1 + e^{\frac{\sigma k}{k_{\max}}})} \right] \omega^0 \quad (5)$$

其中 σ 为正系数, 以调节 ω 的变化速度; k_{\max} 为迭代次数的上限; ω^0 为 $\omega(k)$ 的上限; k 为当前迭代次数。

上述 PSO 算法是在完全信息共享条件下的粒子群优化算法。现讨论在非完全信息共享条件下 PSO 优化算法, 在此引入《高等数学》中的“邻域”概念, 粒子群中每个粒子最多只能认知(或观察)并利用周围一定数目或一定区域内的其他个体信息, 这就是“粒子群邻域”。由此简化粒子群优化更新公式:

$$\begin{cases} v_{id}^{(k+1)} = \omega v_{id}^{(k)} + r(P_{id}^{(k)} - x_{id}^{(k)}) \\ x_{id}^{(k+1)} = x_{id}^{(k)} + v_{id}^{(k+1)} \\ v_{id}^{(1)} = a(1)v_{id}^{(0)}, \dots, v_{id}^{(m)} = a(m)v_{id}^{(0)}, \dots, v_{id}^{(j)} = a(j)v_{id}^{(0)}; m = 1, 2, \dots, j \\ x_{id}^{(1)} = x_{id}^{(0)} + v_{id}^{(1)}, \dots, x_{id}^{(m)} = x_{id}^{(0)} + v_{id}^{(m)}, \dots, x_{id}^{(j)} = x_{id}^{(0)} + v_{id}^{(j)}; m = 1, 2, \dots, j \end{cases} \quad (6)$$

其中: $P_{id}^{(k)}$ 为 $x_{id}^{(k)}$ 所在邻域中最佳粒子位置, 又称邻域极值; r 为 $[0, 1]$ 中随机数。式(1)中第1部分为速度冲量, 第2部分相当于传统粒子群优化算法中社会认知部分, 但此时仅考虑邻域内的粒子最优位置。对式(6)中新生粒子, 采取如下处理: 新生粒子保存策略以满足自然界中优胜劣汰思想, 只有 $x_{id}^{(k+1)}$ 优于 $x_{id}^{(k)}$ 时才被保留。

考虑新生粒子与先前粒子的优劣, 粒子群优化算法中粒子速度可以被分为两类: 一类由此速度向量产生的新粒子优于先前粒子, 称之为优势粒子速度; 另一类是称之为劣势粒子速度。粒子速度更新策略思想为: 提高粒子质量的优势粒子速度被保留并进行全局寻优, 而劣势粒子速度参与细化搜索。

对基本 PSO 算法中式(1)的分析表明, 式(1)中第1项即 $\omega v_{id}^{(k)}$ 体现了粒子的飞行惯性, 采用固定的 ω 值时, 粒子的全局搜索能力和局部精细搜索能力的平衡性较差, 因而在算法运行初期, 粒子能较快地飞向当前的全局最优值, 但是当靠近全局最优值时又往往会因为固定不变的飞行惯性而不能对最优值进行精细搜索, 从而使得收敛精度不高。本文提出的 MPSO 算法采用随迭代次数逐步减小的 ω 值, 能灵活地调整粒子在全局和局部搜索能力之间的平衡, 从而既可在初期有较高的收敛速度, 又可在后期有较高的收敛精度。

文献[8]证明了基本 PSO 算法在解空间中搜索的遍历性不能得到保证, 因而在理论上不能保证收敛到全局最优。本文的 MPSO 在基本 PSO 算法的基础上引入了速度变系数和“邻域”选择算法, 保持了粒子群的多样性, 使算法在解搜索空间中的遍历性得到改善, 因而更有可能获得全局最优。

2 MPSO-BP 神经网络混合优化算法

将 MPSO 优化算法与 BP 神经网络算法结合起来形成一种混合算法: 应用 MPSO 优化算法算出 BP 神经网络的连接权向量和阈值, 即设粒子群的位置向量 x 的元素是 BP 神经网络的所有节点之间的连接权值和阈值, 每次迭代求出最优粒子的权向量和阈值, BP 神经网络在这组权向量和阈值的实际输出值 d_i ($i = 1, 2, \dots, n$; n 是神经网络输入输出的样本对数)。

选取 N 个粒子构成粒子群, 其中每个粒子都是 D 维向量。这个向量代表神经网络模型中的所有权值, 所有权值的初始值随机产生, 取值范围为 $[0, 1]$ 。粒子初始群体随机产生后, 以后各代粒子的位置根据飞行速度的变化而变化。用以下公式衡量每个粒子的适应值:

$$fit = \frac{1}{n} \sum_{i=1}^n \sum_{k=1}^m (d_i - t_k)^2 \quad (7)$$

其中: d_i 是神经网络的实际输出, t_k 是目标输出, m 是输出节

点数, n 是训练集样本数。

2.1 MPSO-BP 神经网络混合优化算法的实现

1) 初始化。确定算法的参数: 根据神经网络的输入输出样本集确定网络的拓扑结构; 按式(3)、(4) 初始化粒子的位置 x_{id} 及速度 v_{id} , 确定粒子个数 N 、惯性因子 ω 的初值、最大允许迭代步数 k_{\max} 、加速系数 c_1 和 c_2 、初始化 P_{id} 和 P_{gd} ;

2) 评价。以神经网络均方差作为适应度函数(fit) 计算出每个粒子的个体极值(适应度值), 选出个体极值最好的作为全局极值, 记为 P_{gd} , 记录该最好值的粒子序号, 那么该粒子对应的极值就是下次迭代中神经网络的最优权值;

3) 更新极值。计算出每一粒子的适应度值 fit_i , 若优于该粒子当前的个体极值, 则将 P_{id} 设置为该粒子的位置, 且更新个体极值。若所有粒子的个体极值中最好的优于当前全局极值, 则将 P_{gd} 设置为该粒子的位置, 记录该粒子的序号, 且更新全局极值;

4) 更新惯性权重。根据式(5) 更新;

5) 更新位置和速度。根据式(3)、(4) 或(6)、(4) 更新;

6) 检验。迭代达到最大次数或最小误差要求时, 停止迭代, 全局极值对应的神经网络权值与连接结构, 即为训练问题的最优解。否则转到 2)。

在 MPSO 全局寻优的基础上, 运行小步长反向传播算法, 进行局部细致搜索, 达到要求的收敛精度。网络权值训练完成后, 将这个最优的权值作为 BP 网络的权值, 进行短期电力负荷预测。

3 MPSO-BP 神经网络负荷预测模型和应用

改进的粒子群算法(MPSO)与 BP 神经网络相结合的预测模型, 称为 MPSO-BP 算法。其算法过程如下: 首先用 MPSO 算法反复优化 BP 模型的权值参数组合, 直至解的适应度不再有意义地增加为止, 即解群质量趋于稳定。此时解码得到的参数组合已较接近符合应用需要的最佳组合。在此基础上, 再用 BP 算法对所得网络参数进一步精确优化, 直至搜索到最优网络参数, 此时即可得到精确的最优参数组合。由于改进的粒子群算法代替了神经网络的初始寻优, 网络仅在已接近最优解的基础上进行参数寻优, 从而有效提高了网络寻优速度和精度。

3.1 预测模型的网络结构

改进的粒子群 BP 神经网络系统采用三层 BP 网络, 它的构成为: 输入量是 65 个; 顺序 1~28 对应于预测日前 1 周相应日 24 h 负荷值和日最高、最低温度、天气; 顺序 29~57 对应于预测日前 1 天 24 h 值和日最高、最低预报温度、天气; 58 对应于预测日前 1 天日类型; 59 对应于预测日前 2 天雨量 Rain2; 60 对应于预测日前 3 天雨量 Rain3; 61 对应于预测日日类型; 62~65 对应于预测日的最高和最低预报温度、天气。隐含层共一层 56 个神经元。输出量是 24 个, 对应于预测日 24 h 负荷的预测值。本文采用百分误差、均方误差和准确度作为分析指标。

3.2 学习样本的选择

为保证训练样本能够覆盖整个样本空间, 更为全面地反映负荷的各种特性, 本文的训练数据选择贵州省电网 2007 年 7 月到 2008 年 7 月的负荷数据、天气数据和气象数据形成样本集, 且训练样本和测试样本按 8:2 比例划分。本文拟选取预测日前 5 个工作日的负荷作为训练数据对该省 2008 年 8 月的电力负荷进行预测(见 3.4 节)。

3.3 输入变量的处理

上面提到输入信息为负荷、气象、天气和日类型等量, 这

些量纲不一(有些并无量纲)、数值各异, 差异甚大。为避免因输入量值域范围的较大差异而导致某些负荷影响因素在总体映射效果中的歪曲甚至淹没现象的发生, 必须对输入的有关变量进行量化处理。另外, 神经网络在训练和学习中, 如果直接使用原始数据, 往往会出现神经元饱和现象, 因此须对所有输入数据进行归一化处理。

3.4 负荷预测仿真与分析

为了验证所述方法和所建模型的可行性和有效性, 本文以贵州电网 2007 年 7 月至 2008 年 7 月的负荷数据为依据, 进行了网络训练和负荷预测计算。

在网络训练过程中, 采用 MPSO 和 BP 相结合的训练方法, MPSO-BP 的初始参数分别为: $\sigma = 0.7$, 惯性因子 $\omega = 0.6$, $\omega^0 = 0.9$, $c_1 = 2$ 和 $c_2 = 2.2$, r_1, r_2 范围 $[0, 1]$; 网络基本参数设置为: 网络学习参数 $\alpha = 0.07$, $\eta = 0.80$, 粒子群 $M = 80$, 初始隐层神经元数目 $n_c = 56$, 最大进化代数 1000。

图 1 是 MPSO-BP 混合算法仿真计算中适应度函数值的迭代过程。迭代开始时函数值比较高且迅速下降, 迭代进行到 60 次以后适应值逐步稳定且降低到 1 以下。适应度函数为神经网络实际输出与目标输出的均方差, 适应度值越小, 表示预测值与真实值越接近。可见 MPSO-BP 网络辨识精度更高。




图 1 适应度函数值变化过程

为进一步评价 MPSO-BP 神经网络模型的仿真效果, 本文采用传统的 BP 神经网络模型、PSO-BP 网络模型和 MPSO-BP 网络模型分别进行模拟, 模型训练结果见表 2。在相同控制精度条件下, BP、PSO-BP 和 MPSO-BP 模型的迭代次数分别为 12066、1150 和 580, 平均相对误差分别为 2.315%、1.711% 和 1.254%。

表 1 BP、PSO-BP 和 MPSO-BP 模型训练性能对比表

模型	控制精度	迭代次数	平均相对误差/%	最大相对误差/%	训练时间/s
BP	0.005	12066	2.315	4.557	162
PSO-BP	0.005	1150	1.711	5.385	103
MPSO-BP	0.005	580	1.254	3.166	96

从表 1 可以看出, MPSO 算法训练 MPSO-BP 神经网络的误差、训练时间和迭代次数都明显优于传统 BP、PSO-BP 算法, 即 MPSO-BP 算法比传统 BP、PSO-BP 算法有着更快的收敛速度和更高的收敛精度, 说明本文采用的这种优化计算是可行的。

图 2 为仿真计算时 MPSO-BP 算法与 PSO-BP 算法的误差演化曲线。在达到同一均方差值时, PSO-BP 算法进行了 1100 余次迭代, 而 MPSO-BP 算法只进行了近 600 次迭代。由此可知 MPSO-BP 算法的迭代次数远远小于 PSO-BP 算法。

可见对同一学习样本集, 应用改进粒子群—BP 神经网络混合算法比其他二种算法的训练时间相对较短、计算精度较高, 这种混合算法收敛速度很快能快速寻优。

为检验 3 种预测模型的预测效果, 表 2 列出了采用 BP、PSO-BP 和 MPSO-BP 神经网络模型所得到的 2008 年 8 月某

日的负荷预测结果的平均相对误差和均方差。该天实际和预测的电力负荷如图3所示。由表2可见,采用 MPSO-BP 网络方法的预测精度明显好于传统 BP 方法和 PSO-BP 方法。BP 网络预测结果容易出现振荡。基于 MPSO-BP 算法神经网络的电网负荷预测模型训练速度快,预报精度高,效果好。




图2 误差演化

表2 某日各小时负荷预测结果的误差比较

方法误差	MPSO-BP 网络方法	PSO-BP 神经网络方法	BP 神经网络方法
均方误差	1.5276	2.0552	2.517
平均相对误差	1.2560	1.7050	2.312

由图3还可以发现,MPSO-BP神经网络方法的百分误差变化比较均匀,变化范围为0%~3%。每一次预测,MPSO-BP神经网络方法耗时70~110s,速度大大提高。

如表2预测误差数据和图3~4所示,采用 MPSO-BP 神经网络的预测精度要高于传统 BP 方法和 PSO-BP 神经网络方法的预测精度。由此算例也可以看出,采用 MPSO-BP 神经网络模型预测电网短期负荷是可行和实用的。

利用 MPSO-BP 神经网络方法,编制成预测软件进行日负荷预测。提取了2008年8月中的3个连续星期的预测结果表明预测准确率平均达到98.8%,最高准确率为99.2%。这对负荷多变、极易受到气象和小水电等因素影响的贵州是不易的。

4 结语

本文分析了传统的粒子群算法及缺点,提出了一种基于改进的粒子群—BP神经网络的短期电力负荷预测方法。该算法先应用 MPSO 算法算出 BP 神经网络的连接权向量和阈值,每次迭代求出最优粒子的权向量和阈值及 BP 网络在这组权向量和阈值的实际输出值,最后得出第 i 个粒子的适应

度函数。采用 MPSO-BP 神经网络算法训练 ANN 网络,实现 BP 网络参数优化,得到改进的粒子群—BP 神经网络负荷预测模型,综合考虑气象、天气、日期类型等影响负荷的因素,进行短期电力负荷预测。算例分析表明:与传统 BP 方法和 PSO-BP 神经网络法相比,本文所研究的方法具有输出稳定性好、收敛性快、预测精度高等优点,并克服了 BP 等前向多层神经网络易陷入局部极小点等和传统的粒子群优化法的缺点。该方法改善了 BP 网络泛化能力,在电力系统短期负荷预测方面具有良好的预测能力,提高了预测的准确率,为电网短期负荷预测提供了一种科学、有效的方法。

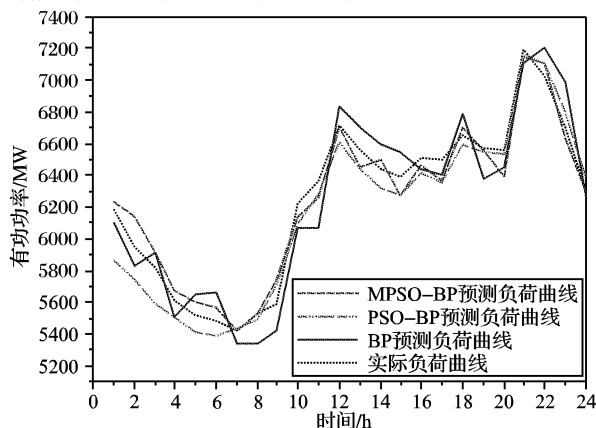


图3 某日24 h实际和预测的电力负荷




图4 某日24 h电力负荷预测的百分误差

参考文献:

- [1] 程其云,孙才新.以神经网络与模糊逻辑互补的电力系统短期负荷预测模型及方法[J].电工技术学报,2004,19(10):53-58.
- [2] 姚建刚,章建,银车来.电力市场运营及其软件开发[M].北京:中国电力出版社,2002.
- [3] 王武,张元敏,蔡子亮.基于遗传优化神经网络的电力系统短期负荷预测[J].继电器,2008,36(9):40-47.
- [4] 张志毅,陈允平,袁荣湘.电力系统负荷恢复问题的混合遗传算法求解[J].电工技术学报,2007,22(2):10-109.
- [5] 葛哲学,孙志强.神经网络理论与MATLABR2007[M].北京:电子工业出版社,2005:67-69.
- [6] 王波,王灿林,梁国强.基于粒子群寻优的D-S算法[J].传感器与微系统,2007,26(1):84-86.
- [7] SENTHIL ARUMUGAM M, RAO M V C, CHANDRAMOHAN A. A new and improved version of particle swarm optimization algorithm with global-local best parameters[J]. Knowledge and Information Systems, 2008,16(3):331-357.
- [8] OMKAR S N, MUDIGERE D, NARAYANA NAIK G, et al. Vector evaluated particle swarm optimization for multi-objective design optimization of composite structures[J]. Computers and Structures, 2008,86(1/2):1-14.